

# Regresión Lineal

$$x \in \mathbb{R}^n \quad x = (x^{(1)}, x^{(2)}, \dots, x^{(n)})$$

$$\begin{bmatrix} x^{(1)} \\ x^{(2)} \\ \vdots \\ x^{(m)} \end{bmatrix} \begin{bmatrix} x_1^{(1)}, x_2^{(1)}, \dots, x_n^{(1)} \\ x_1^{(2)}, x_2^{(2)}, \dots, x_n^{(2)} \\ \vdots \\ x_1^{(m)}, x_2^{(m)}, \dots, x_n^{(m)} \end{bmatrix} \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(m)} \end{bmatrix}$$

$x$


## Notación

$$w = [w_1, w_2] \quad \text{feature extractor } \phi(x) = [1, x]$$

↑  
feature vector

$$f(w) = w \cdot \phi(x) \text{ score}$$

$$\phi(x) = (\phi(x)_1, \phi(x)_2, \dots, \phi(x)_m)$$



$$\phi(x) = (1, x_1, x_2, \dots, x_m)$$

Asumimos que existe

$$h_w(x) = w^T \phi(x) \quad w \in \mathbb{R}^{n+1}$$

$$X = X_1 \quad \phi(x) = [1, x_1]$$

$$w = [w_0, w_1] \quad h_w(x) = [w_0, w_1] \begin{bmatrix} 1 \\ x_1 \end{bmatrix} = w_0 + w_1 x_1$$

$$h_w(x) = \sum_{i=1}^n w_i x_i + w_0 = w^T x + b$$

$$F = \{f_w : w \in \mathbb{R}^2\}$$

# Función de Pérdida




$$\text{loss}(y, \hat{y}) = \frac{1}{2} (y - \hat{y})^2$$

$$E_{in}(h_\theta) = \frac{1}{n} \sum_{i=1}^n \text{loss}(y_i, h_\theta(x^{(i)}))$$

$$E_{in}(h_\theta) = \frac{1}{m} \sum_{i=1}^m \frac{1}{2} (y^{(i)} - \theta^\top \phi(x^{(i)}))^2$$

Min Square Error


$$W^* = \arg \min_{W \in \mathbb{R}^{n+1}} \frac{1}{2m} \sum_{i=1}^m (y^{(i)} - \sum_{j=1}^n w_j x_j - w_0)^2$$



Dado que es cuadrático, es una función convexa.

Tiene un solo mínimo global

**Gradiente:** Es la dirección que más incrementa la pérdida en el entrenamiento



$x_0, f(x_0), f'(x_0)$  ↙ Paso / Tasa de aprendizaje

$$x_1 \rightarrow x_0 - \alpha f'(x_0)$$

$$x_2 \rightarrow x_1 - \alpha f'(x_1)$$

$$\vdots$$

$$x_n \rightarrow x_{n-1} - \alpha f'(x_{n-1})$$

$$\nabla f(x_1, x_2, \dots, x_m) = \begin{bmatrix} \frac{\partial f}{\partial x_1} \\ \vdots \\ \frac{\partial f}{\partial x_m} \end{bmatrix}$$

$$\frac{\partial f(w)}{\partial w_k} = -\frac{1}{m} \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)}) x_k$$

$$\nabla E_{out}(w) = -\frac{1}{m} \begin{bmatrix} \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)}) \cdot 1 \\ \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)}) \cdot x_1^{(i)} \\ \vdots \\ \sum_{i=1}^m (y^{(i)} - \hat{y}^{(i)}) \cdot x_n^{(i)} \end{bmatrix}$$

$$\nabla E_{out}(w) = -\frac{1}{m} (y - \hat{y})$$

$w \leftarrow w - \eta \nabla E_{out}(w)$

Para epoch de 1 a max\_epoch  
 $\hat{y}^{(i)} \in w^T \phi(x^{(i)}) \quad \forall i: 1 \dots n$

$$e^{(i)} \leftarrow y^{(i)} - \hat{y}^{(i)} \quad \forall i: 1 \dots n$$

$$E_{in} \leftarrow \frac{1}{m} \sum_{i=1}^m e^{(i)^2} \quad \text{MSE}$$

$$\nabla w \leftarrow$$

Si  $\|\nabla w\| < tol$   
 return  $w$

$$w \leftarrow w - \eta \nabla w$$

Fin Para

return  $w \leftarrow$  Después de todas las iteraciones

$$\phi(x) = \begin{bmatrix} 1, x_1^{(1)}, \dots, x_n^{(1)} \\ 1, x_1^{(2)}, \dots, x_n^{(2)} \\ \vdots & \ddots & \vdots \\ 1, x_1^{(n)}, \dots, x_n^{(n)} \end{bmatrix} \quad y = \begin{bmatrix} y^{(1)} \\ y^{(2)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

$$\hat{y} = w^T \phi(x^{(i)}) = \phi(x^{(i)})^T w$$

$w \in \mathcal{W}_{\text{ins}}$

Para epoch de 1 a max\_epoch  
 $\hat{y}^{(i)} \in \phi(x)w$

$$E = y - \hat{y}$$

$$E_{\text{in}} = \frac{1}{M} E^T E$$

$$\nabla_w E_{\text{in}} \leftarrow \frac{1}{M} \phi(x)^T E$$

$$\text{Si } \|\nabla_w E_{\text{in}}\| < \text{Tol:}$$

return  $w$

$$w = w - \eta \nabla_w E_{\text{in}}$$

Fin Para

return  $w$  Después de todas las iteraciones

$$y^{(i)} \in \{-1, 1\}$$


$$\begin{aligned} X^{(i)} &= \{x_1^{(i)}, \dots, x_n^{(i)}\} \in \mathbb{R}^n \\ \phi(x^{(i)}) &= \{1, x_1^{(i)}, \dots, x_n^{(i)}\} \in \mathbb{R}^{n+1} \\ w = (w_0, w_1, \dots, w_n) &\in \mathbb{R}^{n+1} \end{aligned}$$

$$\hat{y}^{(i)} = h(x^{(i)}) = \text{sign}(\phi(x^{(i)})^T w)$$

$$(w, X + w_0 = 0)$$

Cuando una  $f$  de learning es lineal nos referimos a la relación de los parámetros

$$\begin{aligned} \text{Loss}_{0-1}(x, y, w) &= 1[H_w(x) \neq y] \quad \text{Zero-one loss} \\ &= 1[\underbrace{(\phi(x) \cdot w) y}_\text{Margen} < 0] \end{aligned}$$



Si  $(\phi(x) \cdot w)$  difiere del signo de  $y$ , va a dar  $-1, 1$  en otro caso

$$E_{out}(w) = \frac{1}{N} \sum_{i=1}^m 1[H_w(x^{(i)}) y^{(i)} \leq 0]$$



$$\text{Loss}_{\text{hinge}}(x, y, w) = \max\{1 - (w \cdot \phi(x))y, 0\}$$

Para compensar datos mal clasificados o bien clasificados por muy poco

$$\nabla \text{Loss}_{\text{Hinge}}(x, y, w) = \begin{cases} -\phi(x)y & \text{if } \{1 - (w \cdot \phi(x)y)\} > 0 \\ 0 & \text{en otro caso} \end{cases}$$

$w \in w_{\text{ins}}$

Para epoch de 1 a max\_epoch

$$z^{(i)} = \phi(x^{(i)})^T w \quad \forall i = 1 \dots n$$

$$a^{(i)} = z^{(i)} \text{ if } \text{Sign}(z^{(i)}) = y^{(i)} \quad \forall i = 1 \dots n \quad \text{s: no } \emptyset$$

$$\nabla_w E_{\text{in}} = \frac{1}{n} \sum_{i=1}^n -a^{(i)} y^{(i)}$$

$$w = w - \eta \nabla_w E_{\text{in}}$$

fin para

return W