

$$\frac{\partial E_{in}}{\partial w_j} = \frac{1}{N} \sum - \frac{y^{(i)}}{\hat{y}^{(i)}} \hat{y}^{(i)} (1 - \hat{y}^{(i)}) x_j^{(i)} + \frac{1 - y^{(i)}}{1 - \hat{y}^{(i)}} \hat{y}^{(i)} (1 - \hat{y}^{(i)}) x_j^{(i)}$$

$$= \frac{1}{N} \sum_{i=1}^N [y^{(i)} - \hat{y}^{(i)}] x_j^{(i)}$$

$$\frac{\partial E_{in}}{\partial b} = - \frac{1}{N} \sum [y^{(i)} - \hat{y}^{(i)}]$$

$$\nabla E_{in} = - \frac{1}{N} \begin{bmatrix} \sum [y^{(i)} - \hat{y}^{(i)}] x_1^{(i)} \\ \vdots \\ \sum [y^{(i)} - \hat{y}^{(i)}] x_n^{(i)} \end{bmatrix}$$

Matriz de diseños

$$\downarrow$$

$$X = \begin{bmatrix} x_1^{(1)} & \cdot & \cdot & \cdot & x_m^{(1)} \\ \vdots & & & & \vdots \\ x_1^{(n)} & \cdot & \cdot & \cdot & x_m^{(n)} \end{bmatrix} \quad y = \begin{bmatrix} y^{(1)} \\ \vdots \\ y^{(n)} \end{bmatrix}$$

$$\hat{y} = \text{sign}(Xw + \vec{1}b)$$

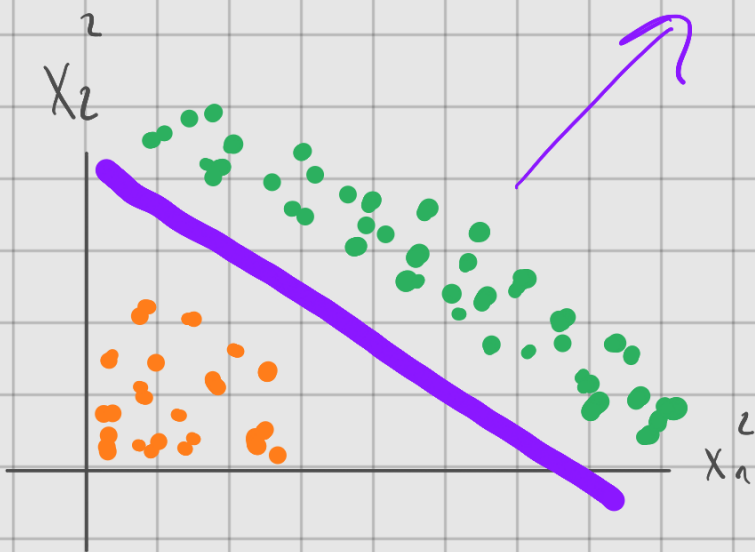

$$\frac{dE_{in}}{db} = \text{promedio}(y - \hat{y})$$

$$-\frac{1}{M} \begin{bmatrix} X_1^{(1)} & X_1^{(2)} & \dots & 0 & 0 & X_1^{(m)} \\ X_2^{(1)} & X_2^{(2)} & \dots & \dots & \dots & X_2^{(m)} \\ \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ X_n^{(1)} & X_n^{(2)} & \dots & \dots & \dots & X_n^{(m)} \end{bmatrix} \begin{bmatrix} y^{(1)} - \hat{y}^{(1)} \\ y^{(2)} - \hat{y}^{(2)} \\ \vdots \\ y^{(n)} - \hat{y}^{(n)} \end{bmatrix}$$

$$= -\frac{1}{M} X^T (y - \hat{y})$$


$$X^{(i)} = (X_1^{(i)}, X_2^{(i)})$$

$$\phi(X^{(i)}) = (X_1^{(i)^2}, X_2^{(i)^2})$$



Los valores negativos se hacen positivos
 Los datos pequeños se acercan más y los datos > 1 se alejan más

Lo transformamos a un espacio donde lo podamos resolver linealmente



$$x^{(i)} = (x_1^i, x_2^i)$$

$$\phi(x^i) = (x_1^i, x_2^i, x_1^{i^2}, x_2^{i^2}, \dots)$$

INGENIERIA DE PARAMETROS

