

$$V^{\pi}(s) = E^{\pi}[R_t | S_t = s]$$

$$V^{\pi}(s) = \sum_{s' \in S} T(s, \pi(s), s') [r(s, \pi(s), s') + \gamma V^{\pi}(s')]$$

$$V^*(s) = E^{\pi^*}[R_t | S_t = s]$$

$Q^{\pi}(s, a)$ Función de valor estado-acción

$$E[R_t | S_t = s, A_t = a]$$

$$Q^{\pi}(s, a) = \sum_{s' \in S} T(s, a, s') * (r(s, a, s') + \gamma Q^{\pi}(s', \pi(s')))$$

$$Q^*(s, a) = \sum_{s' \in S} T(s, a, s') [r(s, a, s') + \gamma \max_{a' \in A(s')} Q^*(s', a')]$$

Políticas ϵ -greedy

$$\pi_{\epsilon}(s) = \begin{cases} \pi(s) & \text{con prob } 1-\epsilon \\ \text{Acción aleatoria} & \text{con prob } \epsilon \end{cases}$$

$$Q^*(s, a) = \sum_{s' \in S} T(s, a, s') [r(s, a, s') + \gamma \max_{a' \in A(s')} Q^*(s', a')]$$

- 1: Tengo el estado s
- 2: Seleccione la acción a con $\pi_\epsilon^*(s) = \begin{cases} \max_{a \in A(s)} Q(s, a) & 1-\epsilon \\ a \in A(s) & \epsilon \end{cases}$
- 3: $\hat{Q}(s, a)$
- 4: Aplíco a al sistema y obtengo s' y r
- 5: Seleccione la acción a' con $\pi_\epsilon^*(s')$
- 6: $\hat{Q}(s, a | s', a') = r + \gamma \hat{Q}(s', a')$
- 7: $\delta = \hat{Q}(s, a | s', a') - \hat{Q}(s, a)$
- 8: $\hat{Q}(s, a) = \hat{Q}(s, a) + \alpha \delta$
- 9: $s = s', a = a'$
- 10: Fuga a 3 pa

SARSA

On policy

def SARSA (mdp, α , ϵ , max_e, max_it, θ):

$Q = \{Q(s, a) : 0 \text{ for } s \text{ in mdp.S for } a \text{ in mdp.acciones-legales}(s)\}$

for _ in range(max_e):

$s = \text{mdp.estado-inicial}()$

$a = \max_{a \in A(s)} [Q(s, a)]$ if random() $\leq 1-\epsilon$ else aleatorio($A(s)$)

for _ range max_it

$s' = \text{mdp.transición}(s, a, s')$

$a' = \max_{a' \in A(s')} [Q(s', a')]$ if random() $\leq 1-\epsilon$ else choice($A(s')$)

$q = Q(s, a) + \alpha [r + \gamma * Q(s', a') - Q(s, a)]$

$\Delta = \max(\Delta, \text{abs}(q - Q(s, a)))$

if terminal(s'):

break

$s = s'$

$a = a'$

if $\Delta < \theta$

break

Q Learning

Off policy

- 1: Tengo el estado s
- 2: Selecciono la acción a con $\pi_{\epsilon}^*(s)$
- 3: $\hat{Q}(s, a)$
- 4: Aplico a al sistema y obtengo s' y r
- 5: $\hat{Q}(s, a | s', a') = r + \gamma \max_{a' \in A(s')} Q(s', a')$
- 6: $\delta = \hat{Q}(s, a | s', a') - \hat{Q}(s, a)$
- 7: $\hat{Q}(s, a) = \hat{Q}(s, a) + \alpha \delta$
- 8: $s = s', a = a'$
- 9: Fuga a 2 pa